DocPilot — izveštaj o napretku

RAG chat sistem nad PowSyBl dokumentacijom · Autor: Vladana · Mentori: Mihajlo Medic, Novo Sandara

Ovaj dokument se dopunjuje posle svake nove funkcionalnosti. Najnovije izmene su u odeljku *Dnevnik izmena* na kraju.

Status po specifikaciji

Nedelja	Zadatak	Status
1	Izbor dokumentacije	Završeno (čeka potvrdu mentora)
1	Konverzija dokumentacije u Markdown	Završeno
1	URL-ovi izvora za citate	Završeno
1	Ingestion: chunkovanje i metapodaci	Završeno
1	Embeddings i FAISS indeks	U toku
1	`POST /chat` vraća top 3 sekcije bez LLM-a, `GET /health`	Nije počelo
1	Istraživanje Markdown biblioteka za WPF	Nije počelo
2	LLM i guardrails	Nije počelo
2	WPF klijent (.NET Framework 4.8)	Nije počelo
3	Evaluacija, ispravke, prezentacija	Nije počelo

Arhitektura i struktura projekta

Backend je u Python-u, jer se tu nalazi ceo RAG ekosistem (sentence-transformers, FAISS, Ollama klijent). Klijent je, po specifikaciji, WPF na .NET Framework 4.8.

```
SE_praksa/
├── docs/
│   ├── specification/   specifikacija zadatka
│   ├── progress/        ovaj izveštaj (Markdown izvor + PDF)
│   └── research/        istraživanje Markdown biblioteka
├── data/
│   ├── raw/             originalni PDF dokumentacije
│   ├── processed/       powsybl.md, source_urls.json, chunks.jsonl
│   └── index/           FAISS indeks (generiše se)
├── backend/
│   ├── ingestion/       konverzija, URL-ovi, chunkovanje, indeksiranje
│   ├── app/             HTTP API
│   └── evaluation/      test pitanja i rezultati
└── frontend/            WPF klijent
```

1. Izbor dokumentacije

Izabrano: PowSyBl (Power System Blocks), dokumentacija biblioteke `powsybl-core`, verzija 7.1.1. PowSyBl je open-source projekat LF Energy / Linux Foundation za modelovanje i simulaciju elektroenergetskih mreža, sa posebnim poglavljima o CIM/CGMES formatu.

Licenca: dokumentacija je pod CC-BY-4.0 (kod pod MPL 2.0), što dozvoljava upotrebu uz navođenje izvora.

Provera uslova iz specifikacije:

Uslov	Ispunjeno
Javna, sa licencom koja dozvoljava upotrebu	Da, CC-BY-4.0
Najmanje 50 strana	Da, oko 260 strana PDF-a (oko 77.000 reči)
Tabele, slike, liste, kod blokovi	Da, svi elementi postoje
Tema koju mogu da procenim	Da, elektroenergetski sistemi i CIM

Razmatrane alternative:

- *EPRI CIM Primer (8. izdanje)* — odbačen: autorska prava EPRI-ja, licenca za ovu upotrebu nije jasna, PDF je šifrovan.
- *MATPOWER User's Manual* — licenca CC BY 4.0, ali ne pokriva CIM.
- *ENTSO-E CGMES Library* — licenca nije jasno navedena za sve dokumente.

2. Konverzija PDF-a u Markdown

Skripta: `backend/ingestion/convert_pdf_to_md.py` · **Rezultat:** `data/processed/powsybl.md`

Upoređena su dva alata na istom PDF-u:

Kriterijum	pymupdf4llm	Docling
Hijerarhija naslova	Očuvana (#, ##, ###)	Svi naslovi na istom nivou
Ugnežđene liste	Očuvane	Spljoštene
Inline kod	Očuvan	Izgubljen
Tabele	Dobre	Dobre
Kod blokovi	Spljošteni u jedan red	Spljošteni u jedan red
Zaglavlja i brojevi strana	Ostaju (uklanjaju se kasnije)	Uklonjeni
Brzina	Nekoliko sekundi	10+ minuta na CPU

Odluka: pymupdf4llm. Hijerarhija naslova je presudna, jer specifikacija traži chunkovanje po naslovima i čuvanje putanje naslova. Šum sa strana se pouzdano uklanja regex-om u chunkeru, dok se izgubljena hijerarhija ne može vratiti.

Pokretanje: `python backend/ingestion/convert_pdf_to_md.py`

3. URL-ovi izvora

Skripta: `backend/ingestion/extract_source_urls.py` · **Rezultat:** `data/processed/source_urls.json`

PDF ne sadrži web adrese sekcija, a specifikacija traži izvore na koje može da se klikne. Skripta čita originalne Markdown izvore dokumentacije za verziju 7.1.1 (sa GitHub-a) i za svaku stranicu i sekciju računa

adresu na powsybl.readthedocs.io, zajedno sa sidrom (`#...`) za direktan skok na sekciju. Svaki URL je proveren na živom sajtu.

Stavka	Broj
Stranica	96 (sve dostupne)
Sekcija	688 (592 sa direktnim sidrom)
Slika sa HTTPS adresom	18 (sve dostupne)

Slike su vezane za sekciju u kojoj se nalaze, pa odgovor može da prikaže tačno odgovarajući dijagram. Sve slike su sa readthedocs-a, u skladu sa zahtevom da se slike učitavaju samo sa pouzdanih HTTPS izvora.

4. Chunkovanje (ingestion)

Skripta: `backend/ingestion/chunk.py` · **Rezultat:** `data/processed/chunks.jsonl`

Šta radi:

1. Uklanja šum iz PDF konverzije: zaglavlja i podnožja strana, brojeve strana, sadržaj, oznake „continues on next page“ i oznake preloma linija u kodu.
2. Deli dokument po naslovima. Nivo naslova se računa iz numeracije (1.1 → 1.1.3 → podsekcija). Znak `#` unutar kod blokova se ne tretira kao naslov.
3. Duge sekcije deli na delove do 350 reči (model bge-small obrađuje najviše 512 tokena). Kod blokovi i tabele se nikada ne seku.
4. Svakom chunku dodaje metapodatke: naslov, putanju naslova, URL izvora i HTTPS slike. Kada isti naslov postoji na više mesta (npr. „BusbarSection“ u Import-u i u Export-u), bira se sekcija sa najviše zajedničkih nadređenih naslova.

Primer metapodataka jednog chunka:

```
title:        ACLineSegment
heading_path: Grid exchange formats > CIM-CGMES > Import > ACLineSegment
url:          .../grid_exchange_formats/cgmes/import.html#cgmes-ac-line-segment-import
part:         1/2
```

Rezultat:

Stavka	Vrednost
Broj chunkova	804
Reči po chunku	min 5, prosek 86, max 350
Chunkovi bez URL-a izvora	0
Chunkovi sa slikama	18
Preostali šum sa strana	0

Otvorena pitanja:

- 87 chunkova ima manje od 15 reči (uglavnom opisi pojedinačnih parametara). Zadržani su jer često sadrže tačan odgovor; ako evaluacija pokaže da smetaju, biće spojeni sa susednim.
- Dugi XML i JSON primeri su posle PDF konverzije u jednom redu. Ne utiče na pretragu, ali utiče na izgled odgovora.

Pokretanje: `python backend/ingestion/chunk.py`

Dnevnik izmena

Datum	Izmena
11.10.2026.	Izbor dokumentacije (PowSyBl 7.1.1), poređenje alata za konverziju, konverzija PDF-a u Markdown
11.10.2026.	Struktura projekta (backend / frontend / data / docs)
11.10.2026.	Izvlačenje i provera URL-ova izvora i slika
11.10.2026.	Chunker sa metapodacima
11.10.2026.	Uveden ovaj izveštaj o napretku