DocPilot — izveštaj o napretku

RAG chat sistem nad PowSyBl dokumentacijom · Autor: Vladana · Mentori: Mihajlo Medic, Novo Sandara

Ovaj dokument se dopunjuje posle svake nove funkcionalnosti. Najnovije izmene su u odeljku *Dnevnik izmena* na kraju.

Status po specifikaciji

Nedelja	Zadatak	Status
1	Izbor dokumentacije	Završeno (čeka potvrdu mentora)
1	Konverzija dokumentacije u Markdown	Završeno
1	URL-ovi izvora za citate	Završeno
1	Ingestion: chunkovanje i metapodaci	Završeno
1	Embeddings i FAISS indeks	Završeno
1	`POST /chat` vraća top 3 sekcije bez LLM-a, `GET /health`	Završeno
1	Istraživanje Markdown biblioteka za WPF	Sledeće
2	LLM i guardrails	Nije počelo
2	WPF klijent (.NET Framework 4.8)	Nije počelo
3	Evaluacija, ispravke, prezentacija	Nije počelo

Arhitektura i struktura projekta

Backend je u Python-u, jer se tu nalazi ceo RAG ekosistem (sentence-transformers, FAISS, Ollama klijent). Klijent je, po specifikaciji, WPF na .NET Framework 4.8.

```
SE_praksa/
├── docs/
│   ├── specification/   specifikacija zadatka
│   ├── progress/        ovaj izveštaj (Markdown izvor + PDF)
│   └── research/        istraživanje Markdown biblioteka
├── data/
│   ├── raw/             originalni PDF dokumentacije
│   ├── processed/       powsybl.md, source_urls.json, chunks.jsonl
│   └── index/           FAISS indeks (generiše se)
├── backend/
│   ├── ingestion/       konverzija, URL-ovi, chunkovanje, indeksiranje
│   ├── app/             HTTP API
│   └── evaluation/      test pitanja i rezultati
└── frontend/            WPF klijent
```

1. Izbor dokumentacije

Izabrano: PowSyBl (Power System Blocks), dokumentacija biblioteke `powsybl-core`, verzija 7.1.1. PowSyBl je open-source projekat LF Energy / Linux Foundation za modelovanje i simulaciju elektroenergetskih mreža, sa posebnim poglavljima o CIM/CGMES formatu.

Licenca: dokumentacija je pod CC-BY-4.0 (kod pod MPL 2.0), što dozvoljava upotrebu uz navođenje izvora.

Provera uslova iz specifikacije:

Uslov	Ispunjeno
Javna, sa licencom koja dozvoljava upotrebu	Da, CC-BY-4.0
Najmanje 50 strana	Da, oko 260 strana PDF-a (oko 77.000 reči)
Tabele, slike, liste, kod blokovi	Da, svi elementi postoje
Tema koju mogu da procenim	Da, elektroenergetski sistemi i CIM

Razmatrane alternative:

- *EPRI CIM Primer (8. izdanje)* — odbačen: autorska prava EPRI-ja, licenca za ovu upotrebu nije jasna, PDF je šifrovan.
- *MATPOWER User's Manual* — licenca CC BY 4.0, ali ne pokriva CIM.
- *ENTSO-E CGMES Library* — licenca nije jasno navedena za sve dokumente.

2. Konverzija PDF-a u Markdown

Skripta: `backend/ingestion/convert_pdf_to_md.py` · **Rezultat:** `data/processed/powsybl.md`

Upoređena su dva alata na istom PDF-u:

Kriterijum	pymupdf4llm	Docling
Hijerarhija naslova	Očuvana (#, ##, ###)	Svi naslovi na istom nivou
Ugnežđene liste	Očuvane	Spljoštene
Inline kod	Očuvan	Izgubljen
Tabele	Dobre	Dobre
Kod blokovi	Spljošteni u jedan red	Spljošteni u jedan red
Zaglavlja i brojevi strana	Ostaju (uklanjaju se kasnije)	Uklonjeni
Brzina	Nekoliko sekundi	10+ minuta na CPU

Odluka: pymupdf4llm. Hijerarhija naslova je presudna, jer specifikacija traži chunkovanje po naslovima i čuvanje putanje naslova. Šum sa strana se pouzdano uklanja regex-om u chunkeru, dok se izgubljena hijerarhija ne može vratiti.

Pokretanje: `python backend/ingestion/convert_pdf_to_md.py`

3. URL-ovi izvora

Skripta: `backend/ingestion/extract_source_urls.py` · **Rezultat:** `data/processed/source_urls.json`

PDF ne sadrži web adrese sekcija, a specifikacija traži izvore na koje može da se klikne. Skripta čita originalne Markdown izvore dokumentacije za verziju 7.1.1 (sa GitHub-a) i za svaku stranicu i sekciju računa

adresu na powsybl.readthedocs.io, zajedno sa sidrom (`#...`) za direktan skok na sekciju. Svaki URL je proveren na živom sajtu.

Stavka	Broj
Stranica	96 (sve dostupne)
Sekcija	688 (592 sa direktnim sidrom)
Slika sa HTTPS adresom	18 (sve dostupne)

Slike su vezane za sekciju u kojoj se nalaze, pa odgovor može da prikaže tačno odgovarajući dijagram. Sve slike su sa readthedocs-a, u skladu sa zahtevom da se slike učitavaju samo sa pouzdanih HTTPS izvora.

4. Chunkovanje (ingestion)

Skripta: `backend/ingestion/chunk.py` · **Rezultat:** `data/processed/chunks.jsonl`

Šta radi:

1. Uklanja šum iz PDF konverzije: zaglavlja i podnožja strana, brojeve strana, sadržaj, oznake „continues on next page“ i oznake preloma linija u kodu.
2. Deli dokument po naslovima. Nivo naslova se računa iz numeracije (1.1 → 1.1.3 → podsekcija). Znak `#` unutar kod blokova se ne tretira kao naslov.
3. Duge sekcije deli na delove do 350 reči (model bge-small obrađuje najviše 512 tokena). Kod blokovi i tabele se nikada ne seku.
4. Svakom chunku dodaje metapodatke: naslov, putanju naslova, URL izvora i HTTPS slike. Kada isti naslov postoji na više mesta (npr. „BusbarSection“ u Import-u i u Export-u), bira se sekcija sa najviše zajedničkih nadređenih naslova.

Primer metapodataka jednog chunka:

```
title:        ACLineSegment
heading_path: Grid exchange formats > CIM-CGMES > Import > ACLineSegment
url:          .../grid_exchange_formats/cgmes/import.html#cgmes-ac-line-segment-import
part:         1/2
```

Rezultat:

Stavka	Vrednost
Broj chunkova	804
Reči po chunku	min 5, prosek 86, max 350
Chunkovi bez URL-a izvora	0
Chunkovi sa slikama	18
Preostali šum sa strana	0

Otvorena pitanja:

- 87 chunkova ima manje od 15 reči (uglavnom opisi pojedinačnih parametara). Zadržani su jer često sadrže tačan odgovor; ako evaluacija pokaže da smetaju, biće spojeni sa susednim.
- Dugi XML i JSON primeri su posle PDF konverzije u jednom redu. Ne utiče na pretragu, ali utiče na izgled odgovora.

Pokretanje: `python backend/ingestion/chunk.py`

5. Embeddings i FAISS indeks

Skripte: `backend/ingestion/build_index.py` (pravi indeks), `backend/app/retriever.py` (pretraga) · **Rezultat:** `data/index/`

Izbori:

Deo	Izbor	Zašto
Embedding model	`BAAI/bge-small-en-v1.5` (384 dimenzije)	Mali open-source model koji preporučuje specifikacija; radi na CPU, dokumentacija je na engleskom
Vektorska baza	FAISS `IndexFlatIP` sa normalizovanim vektorima	Preporuka iz specifikacije; skalarni proizvod normalizovanih vektora je kosinusna sličnost, a tačna pretraga je dovoljno brza za 804 vektora
Tekst koji se embeduje	putanja naslova + tekst chunka	Kratke sekcije (npr. jedan parametar) dobijaju kontekst iz nadređenih naslova
Pitanje	prefiks koji preporučuju autori bge modela	Poboljšava poklapanje kratkih pitanja sa dužim pasusima

Rezultat: 804 vektora, indeks se pravi za oko 80 sekundi na CPU. Indeks se ne čuva u git-u jer se generiše iz `chunks.jsonl`.

Prva provera pretrage (top 3 sekcije, skor = kosinusna sličnost):

Pitanje	Najbolji pogodak	Skor
How are ACLineSegments imported from CGMES?	CIM-CGMES > Import > ACLineSegment (2. i 3. mesto; 1. mesto DCLineSegment)	0.79
Which CGMES versions are supported?	CIM-CGMES > Format specification	0.84
How do I configure the default load flow provider?	Load flow > Configuration	0.79
What is a dangling line?	Network and subnetwork > Dangling line	0.76
How to run a security analysis with itools?	iTools > iTools security-analysis	0.89
What parameters does short-circuit analysis have?	Short-circuit analysis > Parameters	0.79
What is the capital of France? *(nije u dokumentaciji)*	—	0.46
How do I bake chocolate cake? *(nije u dokumentaciji)*	—	0.48
How do I install Kubernetes on Ubuntu? *(nije u dokumentaciji)*	—	0.63

Pitanja na koja dokumentacija ima odgovor dobijaju skor 0.74–0.89, a pitanja van teme 0.46–0.63. To je dobra osnova za guardrail „odbij ako je pretraga slaba“ iz 2. nedelje: prag će biti između ove dve grupe (okvirno oko 0.68), a tačna vrednost biće određena na evaluacionom skupu pitanja.

Otvorena pitanja:

- Kod pitanja o ACLineSegment, sekcija DCLineSegment je na prvom mestu jer su tekstovi vrlo slični. Ispravna sekcija je i dalje u top 3, što je metrika iz specifikacije. Ako se ovo ponavlja u evaluaciji, rešenje je hibridna pretraga (BM25 + vektori, bonus iz specifikacije) ili reranker.
- Pitanja van teme ali tehnička (Kubernetes) imaju viši skor (0.63) od potpuno nepovezanih, pa prag mora biti proveren i na takvim pitanjima.

Pokretanje:

```
python backend/ingestion/build_index.py
python backend/app/retriever.py "Which CGMES versions are supported?"
```

6. HTTP API (`/chat` i `/health`)

Kod: `backend/app/main.py` · **Dokumentacija API-ja:** `backend/API.md` i interaktivno na `http://localhost:8000/docs`

Izbor okvira: FastAPI. Iz definicija zahteva i odgovora automatski pravi OpenAPI specifikaciju i Swagger stranicu za isprobavanje, čime je ispunjen zahtev da API bude dokumentovan. Validira JSON i ima ugrađen server (uvicorn).

Ugovor (minimum iz specifikacije):

Endpoint	Zahtev	Odgovor
`POST /chat`	`{ question }`	`{ answer (Markdown), sources[], refused }`
`GET /health`	—	status servera, broj chunkova, embedding model, status LLM-a

Svaki izvor u `sources[]` sadrži naslov, putanju naslova, URL sekcije na readthedocs-u i skor sličnosti. U ovoj verziji `answer` sadrži 3 najrelevantnije sekcije u Markdown-u (naslov, putanja, tekst, slike sa HTTPS adresa, link ka izvoru), bez LLM-a, kako specifikacija traži za 1. nedelju. `refused` je za sada uvek `false`; odbijanje pri slaboj pretrazi dolazi u 2. nedelji.

Provera ulaza (guardrail 4 iz specifikacije):

Ulaz	Odgovor
Prazno pitanje ili samo razmaci	`400` „Pitanje ne sme biti prazno.“
Pitanje duže od 1000 karaktera	`400` „Pitanje je predugo (N karaktera, dozvoljeno 1000).“
Neispravan JSON ili nema polja `question`	`422`

Provera: svi slučajevi iznad testirani su preko pravog HTTP servera. Model i indeks se učitavaju jednom pri startu servera, a odgovor na `/chat` stiže za oko 0,23 s.

Pokretanje:

```
python -m uvicorn app.main:app --app-dir backend --port 8000
```

Dnevnik izmena

Datum	Izmena
11.10.2026.	Izbor dokumentacije (PowSyBl 7.1.1), poređenje alata za konverziju, konverzija PDF-a u Markdown

Datum	Izmena
11.10.2026.	Struktura projekta (backend / frontend / data / docs)
11.10.2026.	Izvlačenje i provera URL-ova izvora i slika
11.10.2026.	Chunker sa metapodacima
11.10.2026.	Uveden ovaj izveštaj o napretku
11.10.2026.	Embeddings (bge-small-en-v1.5) i FAISS indeks, modul za pretragu
15.10.2026.	HTTP API (FastAPI): `POST /chat` sa top 3 sekcije, `GET /health`, provera ulaza, dokumentacija API-ja